

自然语言处理作业 1

NYT 新闻分类：文本表示、性能与误差分析

姓名：马传志 学号：2411788

摘要

本实验在同一 NYT 数据划分上比较二值词袋、计数词袋、GloVe、AG News 与 NYT 训练的 Word2Vec，以及输入长度为 64、微调 3 轮的 BERT。所有传统表示均使用逻辑回归，模型参数只按验证集选择。实验不仅报告 Accuracy 与 Macro-F1，也从类别混淆、语料覆盖、正则化、逐样本错误与输入预算对照解释性能差异。全文计数词袋的测试 Macro-F1 为 96.79%，BERT-64 为 93.95%；而仅使用相同开头内容的计数词袋为 91.47%。这一结果提示：表示能力与可见文本范围共同影响分类效果，不能仅凭模型规模判定优劣。词项贡献与三方错例进一步揭示了主题重叠、平均池化和文本截断对分类结果的影响。

关键词：新闻分类；词袋模型；逻辑回归；Word2Vec；BERT；误差分析

目录

1 任务、数据与实验设计	3
1.1 研究问题与实验方案	3
1.2 数据清理与固定划分	3
1.3 评价、调参及信息隔离	4
1.4 分类器与统一预处理	4
2 Task 1: 词袋表示及可解释性	5
2.1 Binary、计数与补充 TF-IDF	5
2.2 结果与参数选择	5
2.3 训练权重与单篇贡献	6
3 Task 2: 三种来源的 100 维词向量	6
3.1 三组实验的实现与来源	6
3.2 文档池化、未知词与分类器	7
3.3 分类结果与覆盖率	7
3.4 可核查的近邻与覆盖反例	8

3.5	正则化敏感性：验证集证据	8
3.6	补充消融：平均向量再做 L2 归一化	9
3.7	三方错例：覆盖率之外的分类证据	9
4	Task 3: BERT 微调与输入长度分析	11
4.1	模型、tokenization 与训练设置	11
4.2	训练曲线与结果	11
4.3	截断审计与同输入范围对照	12
5	综合比较与统计不确定性	14
5.1	主要模型的总体表现	14
5.2	逐类表现：多数类会掩盖什么	15
5.3	文档长度分层	16
5.4	配对比较与结论强度	16
6	错误案例：从可见证据到解释	17
6.1	案例选择和证据边界	17
6.2	案例 4400：核心事件出现在导语之后	18
6.3	案例 7009：共享语义与不同信息范围	18
6.4	案例 9704：不能把错误都归因于截断	18
6.5	案例 2849：分类边界而非纯输入缺失	18
6.6	案例 4043：体育活动中的退伍军人议题	18
6.7	案例 5964：导语比喻误导主题	18
6.8	案例 7878：第一人称叙述缺少显式主题词	19
6.9	高置信错误与可靠性	19
7	结论、局限与复现	19
7.1	回答研究问题	19
7.2	局限与可检验的改进方向	19
7.3	文件与复现入口	20
7.4	来源及方法参考	21

1 任务、数据与实验设计

1.1 研究问题与实验方案

本实验研究：新闻主题分类中，显式词项统计、平均词向量和预训练上下文表示分别带来什么收益与限制？比较重点不仅是总体准确率，也包括少数类别表现、数据来源、输入范围及错误原因。词袋部分比较 Binary、Count 和 TF-IDF；词向量部分比较 GloVe 预训练向量以及分别在 AG News、NYT 训练集上学习的 Word2Vec；BERT 采用最大输入长度 64、微调 3 轮，并通过较长输入配置分析上下文范围的影响。

1.2 数据清理与固定划分

NYT 原始数据共 11519 条，字段为 text 和 label。检查未发现空文本、缺失标签或相同文本对应冲突标签；有 72 条完全重复记录。为防止同一篇文章跨训练集与测试集造成记忆式收益，先按完整 text 去重，保留 11447 条。原始文件不修改。清理前后的样本数均予以记录，便于核对数据处理过程。

随后采用 seed=42 的分层随机抽样：先分出 20%，再将这部分平分为验证集与测试集，得到近似 80%/10%/10%。两次抽样均 shuffle，符合先随机打乱的原则；分层额外保证类别比例接近。三个集合之间的完全相同文本交集为零。所有方法沿用同一 row_id 划分清单，不因模型表现重新划分。

表 1: 数据清理与固定划分

集合	business	politics	sports	合计
train	1134	1146	6877	9157
valid	141	144	860	1145
test	142	143	860	1145

row_id 为原始 CSV 从 0 开始的数据行号，不包括表头。测试集 sports 占 75.11%，而 business 与 politics 各约 12.4%。始终预测 sports 即可取得 75.11% 的 Accuracy，但 Macro-F1 仅 28.60%，说明必须同时报告两种指标。

AG News 提供 90000 条文本，去除 29 条完全重复记录后为 89971 条，与完整 NYT 的精确文本交集为零。AG 只用于训练词向量，不使用标签。精确去重不能排除改写、近重复或同一事件报道；本实验未实施事件分组或时间外推划分，因此结论适用于当前随机划分。

1.3 评价、调参及信息隔离

$$\text{Accuracy} = \frac{1}{N} \sum_{i=1}^N \mathbf{1}[y_i = \hat{y}_i], \quad (1)$$

$$P_k = \frac{TP_k}{TP_k + FP_k}, \quad R_k = \frac{TP_k}{TP_k + FN_k}, \quad (2)$$

$$F_{1,k} = \frac{2P_k R_k}{P_k + R_k}, \quad \text{Macro-F1} = \frac{1}{3} \sum_{k=1}^3 F_{1,k}. \quad (3)$$

分母为零时按 0 处理。Macro-F1 先逐类计算再平均，不等于将平均 Precision 与平均 Recall 代入调和平均。表中指标均为百分数；“提高 1 个百分点”指两百分数直接相减。

词袋词表、TF-IDF 的 IDF、自训练 NYT 词向量都只拟合 NYT 训练集；AG 词向量只拟合 AG；公开 GloVe 作为固定外部资源。验证集仅用于选择 C 或 BERT checkpoint，测试集不参与梯度更新、词表学习或超参数选择。所有方法均不在选择后合并训练集与验证集重训，以保持数据使用规则一致。

选参统一优先验证集 Macro-F1，LR 平时取较小 C，BERT 平时保留更早 epoch。Binary 与 Count 模型 C 取 0.01、0.1、1；T2 和补充 TF-IDF 取 0.01 至 1000 的六个十倍网格点。不同特征尺度对应的合理 C 不同，数值相同不代表正则化强度可直接比较。模型表现已被用于事后解释，新增消融也沿用原测试集，因此它们属于探索性分析，并非新测试集上的独立确认。

1.4 分类器与统一预处理

非 BERT 模型均使用小写化与正则分词，保留至少两个字母、数字或下划线组成的 token；不删停用词，不做词干化。该规则对所有词袋和词向量方法一致。分词统一采用 CountVectorizer 分析器。

LR 采用 One-vs-Rest、liblinear、L2 正则、带截距、无类别权重、seed=42。每类分别拟合一个二元分类器，预测时取最大决策得分。类别概率为 OvR 概率的归一化值，不能直接当作校准后的可靠度。达到最大迭代数的收敛警告会被转为错误；实验运行没有未处理的收敛警告。

$$s_k(d) = \mathbf{w}_k^\top \mathbf{x}_d + b_k, \quad \hat{y} = \arg \max_k s_k(d).$$

较大 C 代表较弱正则化。词袋 max_iter=2000，新增 T2 与 TF-IDF 为 5000，增大上限只用于保证求解收敛。对不均衡类别不加权是保持基线一致的选择，不代表类别加权无价值。

2 Task 1: 词袋表示及可解释性

2.1 Binary、计数与补充 TF-IDF

训练集词表大小为 60947。Binary 只记录某词是否出现，Count 保留原始出现次数，不除以文档长度。例如词表为 [team, win, market]，文档 “team team win” 分别得到 [1,1,0] 与 [2,1,0]。未在训练词表出现的测试词被忽略。

$$x_{d,j}^{\text{Binary}} = \mathbf{1}[c_{d,j} > 0], \quad x_{d,j}^{\text{Count}} = c_{d,j}.$$

Binary 降低重复措辞的影响，但抹去了主题词密集程度；Count 保留强度信息，也可能放大背景主题和长文章中重复词的作用。二者均不建模词序，无法直接区分 “体育用于营销” 与 “营销涉及体育” 的主次关系。

补充 TF-IDF 使用原始词频乘平滑 IDF，再做逐文档 L2 归一化：

$$\text{idf}(j) = \log \frac{1 + N_{\text{train}}}{1 + \text{df}(j)} + 1, \quad z_{d,j} = c_{d,j} \text{idf}(j), \quad \mathbf{x}_d = \mathbf{z}_d / \|\mathbf{z}_d\|_2.$$

IDF 只用训练集。TF-IDF 同时改变词项权重和向量尺度，因此若表现变化，不能单独归因于 “抑制停用词”。

2.2 结果与参数选择

表 2: 结果与参数选择

方法	C	验证 Acc	验证 F1	测试 Acc	测试 F1	错数
Binary	1.0	98.52	96.31	98.60	96.85	16
Count	0.1	99.39	98.46	98.69	96.79	15
TF-IDF	100	99.30	98.23	99.04	97.53	11

Count 的验证 Macro-F1 最高，因此按预定规则选 Count 作为 T1 主模型。测试集上 Binary 的 Macro-F1 反而比 Count 高约 0.06 个百分点，而 Count 少错 1 条；这并不矛盾，Macro-F1 对各类等权，不只统计总错数。本文的模型选择保持以验证集结果为依据。

从 Binary 切换到 Count 修正 8 条错误，同时新增 7 条，说明不是单纯在原模型上 “多猜对 1 篇”。Count 把 business 正确数从 132 提升至 133，却将 politics 正确数从 140 降至 139，sports 从 857 升至 858；少数类之间的 Precision/Recall 变化使总体 Accuracy 与 Macro-F1 排序不同。

TF-IDF 取得 11 条错误、测试 Macro-F1 为 97.53%，相对 Count 修正 6 条并新增 2 条。它是本次测试上的最好点估计，但验证 Macro-F1 仍低于 Count。后文配对区间跨零，因此不能把一次测试排名写成稳定优势，这一差异仍需更多独立实验验证。

2.3 训练权重与单篇贡献

表 3: 训练权重与单篇贡献

类别	Count 正权重靠前的词
business	company, european, flight, market, wasserman, business, its
politics	military, mr, washington, republican, law, obama, republicans
sports	players, league, team, game, football, season, club

这些词揭示语料关联：体育类含 players、league、team，商业类含 company、market，政治类含 military、washington、republican。词权重反映条件于当前训练集的预测关联，不是普遍词义，也不是因果作用。例如“mr”等称谓和功能词也进入模型，提示作者文风与栏目习惯可能成为捷径。

对错误类 a 与真实类 b ，使用决策差值而不是仅列某类最大权重：

$$s_a(d) - s_b(d) = (b_a - b_b) + \sum_j x_{d,j}(w_{a,j} - w_{b,j}).$$

每个词的贡献等于实际输入值乘类别权重差。正值推向错误类，负值支持真实类，截距也必须计入总差；只看单词系数而不乘出现次数会误判 Count 模型的证据。

row_id=4043 实际为 sports，讲女性退伍军人的高尔夫康复活动，Count 误判 politics。veterans 出现 19 次，向错误类贡献 +3.931；golf 出现 13 次，支持真实类贡献-3.505；club 的贡献为-2.356。模型同时识别两类信号，但整篇累积后的线性边界落在 politics 一侧。该例说明跨主题文章的叙事中心不能由是否出现体育词唯一确定。

row_id=4113 真实 business，讨论保险监管与既有保单。insurance 出现 14 次却对 politics 相对 business 贡献 +3.691，state 贡献 +2.198；companies、consumers 分别贡献-1.161、-0.987。不能按日常常识把 insurance 自动视作商业词：本数据中保险与医疗政策报道高度相关，模型学到的是训练语境中的共现。完整词项贡献保存在 T1 结果 JSON 中，可回查而不是依赖主观猜测。

3 Task 2: 三种来源的 100 维词向量

3.1 三组实验的实现与来源

GloVe 使用 glove.6B.100d.txt，共 400000 词、每词 100 维，来自斯坦福官方 glove.6B.zip。官方说明该 6B 模型由 Wikipedia 2014 与 Gigaword 5 语料训练。下载时只读取 ZIP 中的 100d 成员，并由 ZIP CRC 校验完整性；完整文件 SHA-256 保存在来源记录中。

GloVe 利用全局词词共现统计学习表示；Word2Vec 在局部上下文预测任务中学习向量。本实验两种自训练来源统一采用 Skip-gram 与负采样，固定 100 维、window=5、min_count=2、negative=5、sample=0.001、epochs=10、workers=1、seed=42，使用稳定 CRC32 词哈希。先按句末标点切分句子，再用统一分析器分词，以免窗口跨越无关句子。

AG 组只在 89971 条 AG 文本训练；NYT 组只用 9157 条 NYT 训练文本，复用已完成并校

验过的同参数 Skip-gram 向量，不用验证集或测试集训练词向量。三组采用相同的文档池化方法与分类器，比较不同词向量来源的效果。

3.2 文档池化、未知词与分类器

对文档中有向量的所有词取平均，重复出现的词重复参与求和；不存在向量的词跳过。这里分母为有效 token 数量，而不是原文词数或不同词的数量。全篇无已知词时使用 100 维零向量，并统计该情况；此次三组在所有划分中均没有零向量文档。

$$\mathcal{I}_d = \{i : w_i \in V_{\text{emb}}\}, \quad h(d) = \frac{1}{|\mathcal{I}_d|} \sum_{i \in \mathcal{I}_d} e(w_i).$$

分类时直接用该平均向量训练 LR，不额外归一化；L2 归一化只作为独立补充消融。无监督词向量在分类阶段保持固定，不接受 NYT 标签的反向传播。100 维平均向量比 60947 维稀疏词袋紧凑，但将每篇文档压缩为一个中心点，会丢失词序、不同主题段落的位置和部分稀有判别词信息。

3.3 分类结果与覆盖率

表 4: 分类结果与覆盖率

来源	词表大小	测试覆盖率	C	验证 F1	测试 Acc	测试 F1
GloVe	400000	99.76	100	97.53	98.08	95.58
AG-W2V	37021	97.05	100	95.98	97.90	94.99
NYT-W2V	43337	99.18	100	97.15	98.34	96.04

覆盖率按已知 token 总数除以总 token 数计算，计入重复词，不是词类型覆盖率。GloVe 覆盖率最高，但测试 Macro-F1 并未最高；NYT 词向量测试 Macro-F1 高于 AG 约 1.05 个百分点，高于 GloVe 约 0.46 个百分点。差异很小且配对区间均跨零，应将“同域语料可能有帮助”作为解释线索，而不是已被确定证明的普遍规律。

AG 有近 9 万篇，数量多于 NYT 训练集约 9 千篇，但不能仅按文档数量判断训练资源。AG 训练句子的 token 总量约 338 万；NYT 训练文本经统一文档分析器得到约 572 万 token，且 NYT 文章更长。来源、长度、词频分布与共现样本总量共同变化，所以当前实验不是只改变“域”的严格单因素实验。

GloVe 的高覆盖率主要避免未知词丢失，却不能保证平均向量能保持分类所需的主次关系。外部向量中的语义近邻也未必对应本作业的栏目标签。比如 government 与 economy 相关是合理语言现象，却可能使 business/politics 两类更难通过平均向量分开。

3.4 可核查的近邻与覆盖反例

表 5: 可核查的近邻与覆盖反例

来源	market 最近邻	government 最近邻
GloVe	markets, stock, prices	administration, governments, officials
AG-W2V	cooled, markets, fundamentals	upa, ministries, iyad
NYT-W2V	markets, economy, stocks	shutdown, federal, economy

GloVe 中 market 邻近 markets、stock、prices, NYT 中 government 邻近 shutdown、federal、economy, 体现当前 NYT 政治经济报道的语境。AG 的一些近邻是专名或较生僻词, 说明有限语料与词频估计会影响近邻质量; 这里只作局部观察, 不能根据三个词的近邻直接评定整体向量优劣。

进一步按每篇文档覆盖率 98% 分组: AG 低覆盖组 812 篇、错 15 篇, 准确率 98.15%; 高覆盖组 333 篇、错 9 篇, 准确率 97.30%。GloVe 低覆盖组只有 11 篇且恰好全对, 样本太少不宜推断。这个反例表明覆盖率与错误并非简单单调关系, 文章主题、长度和难度都是混杂因素; 不能写成“所有错误都由 OOV 导致”。

3.5 正则化敏感性: 验证集证据

表 6: 正则化敏感性: 验证集证据

C	GloVe 验证 F1	AG 验证 F1	NYT 验证 F1
0.01	81.54	40.73	52.45
0.1	93.08	89.38	90.19
1	96.39	93.84	93.91
10	97.40	95.14	96.97
100	97.53	95.98	97.15
1000	97.53	95.85	96.92

三组均选择 C=100, GloVe 在 100 与 1000 上平分而取较小值。小 C 时较强的收缩会令 100 维密集表示难以划出合适边界, 特别是少数类; 放松正则后验证 F1 明显上升。继续增大到 1000, AG 与 NYT 没有改善, 提示不能简单认为 C 越大越好。模型选择使用验证表现, 而不是挑测试最高的 C。

3.6 补充消融：平均向量再做 L2 归一化

表 7: 补充消融：平均向量再做 L2 归一化

来源	原平均 C	原平均测试 F1	L2 后 C	L2 后测试 F1
GloVe	100	95.58	100	95.78
AG-W2V	100	94.99	1000	95.12
NYT-W2V	100	96.04	1000	96.04

两种处理各自用相同六点网格在验证集选 C，测试差异均很小。NYT 归一化后总错数仍为 19，但类别分配稍变，所以 F1 并不完全相同。AG 和 NYT 归一化版本选到网格上界 1000，其最佳 C 尚未被上方候选包围，不能宣称已全局调优。归一化改变向量长度和有效正则尺度，所以差异不能仅解释为删除文档长度信息；平均向量范数还受语义一致性和词向量范数影响。

3.7 三方错例：覆盖率之外的分类证据

从三组预测不一致的文章中，事后选取 AG 单独误判、NYT 单独误判、GloVe 单独误判各一例，避免只展示某一来源获胜的样本。这些案例用于解释，不能据此估计三组的总体胜率。完整原文、未知词、概率和逐词贡献保存在 `required_analysis/t2_case_evidence.json`。

表 8: 三方错例：覆盖率之外的分类证据

row_id/真实类	来源	预测	覆盖率 (%)	类别分差
2849/politics	glove	politics	99.83	-3.060
2849/politics	ag	business	99.17	+1.770
2849/politics	nyt	politics	99.50	-0.004
9704/business	glove	business	99.89	-1.295
9704/business	ag	business	96.47	-0.604
9704/business	nyt	sports	97.83	+3.530
11327/business	glove	sports	100.00	+0.588
11327/business	ag	business	98.12	-2.488
11327/business	nyt	business	98.74	-2.175

2849 的分差为 business 减 politics，另外两篇为 sports 减 business；正值支持此处的错误类别。各模型分别训练，分差尺度不能跨模型解释为统一置信度。对固定平均词向量加线性分类器，可精确分解：

$$s_a(d) - s_b(d) = (b_a - b_b) + \sum_{w \in V_d} \frac{c_d(w)}{n_d} (\mathbf{w}_a - \mathbf{w}_b)^\top \mathbf{e}(w).$$

其中 n_d 为已知 token 总数, V_d 为文档中已知词的集合, 重复词由次数 $c_d(w)$ 计入。分析脚本检查“全部词贡献之和加截距”与实际类别分差一致(误差小于 0.0001)。这能定位线性决策的数值来源, 但不是删除该词后的因果效果: 删除词还会改变平均分母。

3.7.1 案例 2849: 保险产品等级与公共政策混淆

文章介绍医保交易平台、联邦政府公布的保险计划与价格, 真实为 politics。AG 判 business, GloVe 和 NYT 正确。三者覆盖率都超过 99%, AG 仅缺失 varieties、comanche、923、optima、064 五个各出现一次的 token。因此不能简单归因为大量政治词缺失。

在 AG 模型中, gold 出现 6 次, 对 business 减 politics 的分差贡献 +1.466; premium 贡献 +0.575, 而 federal 贡献 -0.062、government 贡献 -0.197。原文 gold 和 silver 指保险计划等级; 固定词向量不会随当前语境改变, 平均表示也不保留修饰关系。结合全部词与截距, AG 最终分差为 +1.770, 落入 business。这里不能断言 gold 被内部解释成贵金属, 只能确认其数值贡献推向商业类。NYT 的分差约 -0.004, 虽然正确, 却非常接近边界, 并非同域词向量在此例具有压倒性优势。

3.7.2 案例 9704: 体育题材服务于酒店营销

文章讲万豪借棒球电影推广会员计划, 真实为 business。GloVe 与 AG 正确, NYT 误判 sports。AG 覆盖率 96.47%, 低于 NYT 的 97.83%, 却分类正确, 直接反驳“覆盖率更高就一定分类更好”。AG 未知词包括 facebook、screenings 和 multicultural; 但核心品牌 marriott 在三组词表中都存在。

marriott 出现 24 次, 在 GloVe 和 AG 中对 sports 减 business 分别贡献 -2.135 和 -2.088, 在 NYT 中仅为 -0.177。NYT 的 robinson、baseball、league 分别贡献 +0.805、+0.708、+0.700; 所有词与截距合计后分差为 +3.530。问题不只是未知词, 还涉及已知词向量与分类器共同形成的判别方向。由于三组 LR 也分别训练, 不能把贡献差异全部归因于词向量本身, 更不能由这篇反例推出同域训练普遍无效。

3.7.3 案例 11327: 冰球商品的关税报道

文章讨论加拿大取消体育用品进口关税及零售价格, 真实为 business。GloVe 误判 sports, AG 与 NYT 正确。GloVe 覆盖率 100%, 没有未知词, 说明该错误完全不能用 OOV 解释。hockey 出现 13 次, 对 GloVe 的 sports 减 business 贡献 +3.524; tariffs 和 prices 分别贡献 -0.155 和 -0.401, 最终分差仍为 +0.588。

AG 与 NYT 中的 hockey 同样推向 sports, 贡献分别为 +3.333 和 +3.002, 但全篇其他词与截距共同使分差降为 -2.488 和 -2.175, 得到 business。不能只取最大正贡献词就判断模型输出; 平均表示加 LR 依赖的是整篇净证据。此例和 9704 共同显示, 体育实体既可能是报道主旨, 也可能只是商业活动的对象, 平均池化难以显式区分这两种关系。

三例说明: 覆盖率衡量词是否可用, 逐词贡献解释当前线性分类器怎样累计证据, 二者都不能单独代表篇章理解能力。主结果中 NYT 的测试点估计最高, 但 AG 与 GloVe 各自也有正确而

NYT 错误的样本，因此仍保留三来源差异区间跨零的结论。

4 Task 3: BERT 微调与输入长度分析

4.1 模型、tokenization 与训练设置

使用 google-bert/bert-base-uncased 的预训练权重，固定仓库 revision；添加三分类头，对全部参数微调。模型共有 109484547 个参数。使用标准 BERT 序列分类结构：CLS 位置经过 pooler、dropout 和线性分类头，不把平均词向量送入另一个 LR。

Tokenizer 设置 max_length=64、truncation=True，保留开头最多 62 个正文 WordPiece，再加 CLS 和 SEP。动态 padding，attention_mask 区分正文与 padding，单文本 token_type_ids 均为 0。完整长度只用于统计截断情况，不送入模型训练，也不用于选参。

训练 3 轮，AdamW 学习率 $2e-5$ ，weight_decay=0.01 (bias 和 LayerNorm 权重不衰减)，前 10% 更新线性 warmup，其后线性衰减；梯度裁剪 1.0。micro-batch=16、累积 2 步，有效 batch 约 32；最后不足一组时按实际样本数缩放梯度。验证 batch=32，无类别加权。固定 Python、NumPy 与 Torch 种子 42；不同 CUDA 内核与混合精度环境仍可能出现微小差异。

实验在配备 RTX A6000 48GB 的服务器上进行，PyTorch 2.1.2+cu121、Transformers 4.46.3、Python 3.8.10，使用 BF16。采用验证 Macro-F1 最高的 checkpoint，3 轮训练全部完成后才进行最终测试；本次恰好选中第 3 轮，因此最终结果也对应训练满 3 轮的模型。

4.2 训练曲线与结果

表 9: 训练曲线与结果

Epoch	训练损失	验证损失	验证 Acc	验证 F1
1	0.2785	0.0789	97.38	93.76
2	0.0475	0.0632	97.64	94.38
3	0.0183	0.0707	97.90	94.99




图 1: BERT-64 训练与验证损失

训练损失持续下降，但验证交叉熵在第 2 轮最低，第 3 轮回升；验证 Macro-F1 却继续上升。损失衡量概率质量，F1 衡量离散分类结果，少量更自信的误差即可拉高损失，因此两者不必同步。这里按预先指定的 Macro-F1 选择第 3 轮，不能在看到测试后改用损失最低的 epoch。

最终测试 Accuracy 为 97.12%，Macro-F1 为 93.95%，错误 33 篇。完整运行约 147.3 秒，峰值已分配显存约 2390MiB；该时间包含本脚本的处理、验证与保存，不包含下载预训练权重。不同模型运行平台与统计阶段不同，不能把这些数字当成严格的跨模型速度排名。

4.3 截断审计与同输入范围对照

表 10: 截断审计与同输入范围对照

集合	平均长度	截断篇数/总数	保留比例 (%)
train	833.8	9152/9157	7.44
valid	825.0	1145/1145	7.52
test	826.8	1145/1145	7.50

表中长度单位为正文 WordPiece。测试集 1145 篇均超过可保留的 62 个正文 WordPiece，保留 token 总量仅约 7.50%。这一数值不是“保留 7.50% 的语义信息”：新闻导语往往浓缩核心内容，字符、词与信息量也不成比例。不能因为截断普遍发生，就证明每个错误都由截断导致。

为减少输入范围的混杂，补充 Count-head64：将同一 BERT tokenizer 产生的前 62 个正文 WordPiece 解码为文本，再用 CountVectorizer 与 LR 训练；训练、验证、测试都执行相同处理。原三点网格的最优 $C=1$ 位于上界；本次预先扩展到 0.01、0.1、1、10、100、1000 六点，只按验证 Macro-F1 选 C ，平分取较小值，选定后才计算测试指标。两种模型可见的原文范围相同，但后续分词表示、预训练资源与搜索空间并非完全相同，因此是输入预算对照，不是架构唯一变化的纯因果实验。

表 11: 截断审计与同输入范围对照

配置	测试 Acc	测试 F1	错误数
Count	98.69	96.79	15
Count-head64	95.81	91.47	48
BERT-64	97.12	93.95	33
BERT-512	98.69	96.98	15

表 12: 截断审计与同输入范围对照

短 Count 的 C	验证 Acc	验证 Macro-F1
0.01	90.66	80.88
0.1	94.67	89.12
1	95.46	90.41
10	95.63	90.74
100	95.46	90.35
1000	95.55	90.51

扩展网格选中 $C=10$, 其验证 Macro-F1 为 90.74%, 高于 $C=1$ 的 90.41%; 继续增大至 100 和 1000 均未超过 $C=10$, 最优点已被两侧候选包围。测试 Accuracy 从 95.72% 升至 95.81%, Macro-F1 从 91.33% 升至 91.47%, 错误由 49 篇降为 48 篇。改善有限, 但补足了原先网格边界的疑问; 有限网格仍不等于连续参数的全局最优。

BERT-64 较更新后的短 Count 的 Macro-F1 高 2.48 个百分点, 修正 28 条并新增 13 条错误, 配对 bootstrap 的 95% 区间约为 $[+0.24, +4.77]$ 个百分点。这支持本次同输入范围下预训练方案的收益, 且结论没有因扩大短 Count 搜索而反转。后续分词、预训练资源及模型结构仍不同, 不能把差值解释为单一架构因素的因果效果。由于此次扩展发生在已查看原测试结果之后, 仍属于探索性补充。

BERT-512 (头 255、尾 254 个正文 WordPiece, 双片段) 测试 Macro-F1 为 96.98%, 高出 3.03 个百分点。但长度、位置与 segment 编码同时改变, 这不是只改变长度的严格消融, 其结果反映了输入长度与采样位置共同变化的影响。

5 综合比较与统计不确定性

5.1 主要模型的总体表现

表 13: 主要模型的总体表现

方法	验证 Acc	验证 F1	测试 Acc	测试 F1	错误数
Binary	98.52	96.31	98.60	96.85	16
Count	99.39	98.46	98.69	96.79	15
GloVe	99.04	97.53	98.08	95.58	22
AG-W2V	98.43	95.98	97.90	94.99	24
NYT-W2V	98.86	97.15	98.34	96.04	19
BERT-64	97.90	94.99	97.12	93.95	33




图 2: 主要模型的 Accuracy 与 Macro-F1

在主要模型中，Count 的验证 Macro-F1 最高，应按验证规则选为整体主模型；Binary 测试 Macro-F1 略高不改变这一选择。T2 内部验证分数最高的是 GloVe，而测试最高的是 NYT-W2V，这个排序反转再次说明不能用测试集选模型。TF-IDF 的结果见词袋实验部分，其测试 Macro-F1 点估计最高。

5.2 逐类表现：多数类会掩盖什么

表 14: 逐类表现：多数类会掩盖什么

方法	Business F1	Politics F1	Sports F1
Binary	95.65	95.24	99.65
Count	95.00	95.53	99.83
GloVe	93.91	93.24	99.59
AG-W2V	92.63	92.68	99.65
NYT-W2V	94.20	94.20	99.71
BERT-64	91.55	91.29	99.01

表 15: 逐类表现：多数类会掩盖什么

模型/类别	Precision	Recall	F1	Support
Count/business	96.38	93.66	95.00	142
Count/politics	93.92	97.20	95.53	143
Count/sports	99.88	99.77	99.83	860
BERT-64/business	91.55	91.55	91.55	142
BERT-64/politics	90.97	91.61	91.29	143
BERT-64/sports	99.07	98.95	99.01	860




图 3: 六组模型混淆矩阵，行是真实类别，列是预测类别

体育类样本多且词汇信号清晰，各方法总体表现较高；商业与政治共享监管、保险、税收、能源和政府等主题，是主要混淆边界。例如 AG 词向量把 9 篇 business 判成 politics，又把 9 篇 politics 判成 business；GloVe 对应 10 与 5 篇；NYT 对应 10 与 4 篇。平均向量可能把共享语义拉近，但这只是符合混淆模式的解释，不能当作已观测到的内部因果机制。

BERT-64 在 business 与 politics 之间双向各错 8 篇，还各有 4 篇被判 sports。它也把 9 篇 sports 错分到另外两类。与 Count 相比，sports 正确数从 858 降至 851，politics 从 139 降至 131，business 从 133 降至 130，因此下降不限于单一少数类。

5.3 文档长度分层

表 16: 文档长度分层

普通 token 长度	样本数	B/P/S	Count 错误	BERT-64 错误	短 Count 错误
0-199	86	1/4/81	0	0	0
200-499	270	32/22/216	1	7	7
500-999	730	99/106/525	11	22	31
1000 及以上	59	10/11/38	3	4	10

长度按统一词袋分析器的 token 计数，不能与 BERT WordPiece 数混用。最短组 86 篇中 81 篇为 sports，三模型均全对，不代表短文本普遍容易。最长组仅 59 篇，短 Count 有 10 条错误、BERT-64 有 4 条、全文 Count 有 3 条。不同长度组的类别比例与主题难度不同，所以不能由该表断言“长度增加必然降低准确率”，也不能仅凭相关性量化截断的因果影响。

5.4 配对比较与结论强度

在同一测试集上对样本索引成对 bootstrap，固定 seed=42，重复 3000 次，每次对两个模型使用相同索引；计算后者减前者的 Macro-F1 差值，取 2.5% 与 97.5% 分位数。该区间只反映固定训练模型与当前测试分布下的样本波动，不含重训随机性。另用不一致预测对做精确二项 McNemar 检验，其检验对象是错误率差异，并非直接检验 Macro-F1。

表 17: 配对比较与结论强度

前者 → 后者	修正/新增	F1 差 (百分点)	95% 区间	McNemar p
Binary → Count	8/7	-0.06	[-1.57, +1.46]	1.0000
Count → TF-IDF	6/2	+0.74	[-0.43, +1.97]	0.2891
AG-W2V → NYT-W2V	10/5	+1.05	[-0.39, +2.60]	0.3018
GloVe → NYT-W2V	9/6	+0.46	[-0.83, +1.80]	0.6072
Count → BERT-64	8/26	-2.84	[-5.06, -0.65]	0.0029
Count-head64 → BERT-64	28/13	+2.48	[+0.24, +4.77]	0.0275
BERT-64 → BERT-512	24/6	+3.03	[+1.14, +5.03]	0.0014

Binary/Count、Count/TF-IDF 以及 T2 来源之间的区间均跨零，不支持把小幅排名差距说成稳定提升。Count 到 BERT-64 的 Macro-F1 差区间为负，短 Count 到 BERT-64 为正，和输入预算分析一致。但这些比较含事后选择且未做多重比较校正，应视为探索性证据；不能推广为所有新闻数据或任意训练种子下的定论。

6 错误案例：从可见证据到解释

6.1 案例选择和证据边界

以下案例按错误类型人工选取，旨在解释机制，不是随机样本，也不能据此估计某类原因在全部错误中的占比。每个 row_id 可在原始数据、逐样本预测和 BERT 输入审计中定位。模型原始分数可检查，BERT “关注了哪个词” 没有通过归因实验验证，因此只讨论可见文本与预测的相容解释，相关解释仍需归因实验进一步检验。

表 18: 案例选择和证据边界

row_id	真实	Count	GloVe	NYT-W2V	BERT-64	BERT-512
4400	sports	sports	sports	sports	business	sports
7009	politics	business	business	business	business	politics
9704	business	business	business	sports	sports	sports
2849	politics	politics	politics	politics	business	politics
4043	sports	politics	politics	politics	politics	politics
5964	business	business	business	business	sports	business
7878	sports	business	sports	sports	business	sports

6.2 案例 4400：核心事件出现在导语之后

真实标签 sports。前 62 个正文 WordPiece 主要介绍 Anthony Bosch、商人、投资者与诊所，BERT-64 以约 99.7% 概率判 business；后续才说明诊所牵涉职业棒球兴奋剂丑闻，包括 Major League Baseball 与球员。全文 Count 和 BERT-512 均正确。此处确实能在输入审计中看到关键体育信息被 64 截断排除，支持“主旨延后导致信息不足”的解释；但仍不能证明仅把某一个词补回就必然纠错。

6.3 案例 7009：共享语义与不同信息范围

真实标签 politics，主题为废弃天然气井的公共治理。开头聚焦价格下降、企业消失与破产，64 输入在费用讨论处截断；州长拨款、议会问责等信息在后文。BERT-64 和全文 Count 都判 business，BERT-512 模型正确。Count 虽然读到全文，但 company 与 companies 合计对错误类别贡献约 +7.668，state 则支持 politics 约-5.715，说明它与 BERT-64 错误相同，失误路径却可能不同：一个缺少后文，一个有后文但词项累积边界不合适。

6.4 案例 9704：不能把错误都归因于截断

真实标签 business。文章讲万豪借 Jackie Robinson 电影推广会员计划，开头已经明确包含 marriott、promote、loyalty program 和 campaign，BERT-64 仍判 sports，置信度约 99.6%；BERT-512 也判 sports，而 Count 正确。体育实体在这里服务于商业营销。因为商业线索已在可见输入里，不能声称“BERT 没看到任何商业信息”；更合理的解释是跨主题主次关系没有被正确区分，但需要额外归因或反事实实验才能验证模型具体依赖什么。

6.5 案例 2849：分类边界而非纯输入缺失

真实标签 politics，涉及医保交易平台开放、联邦政府与保险价格。前 62 个 WordPiece 已包含 partisan debate、federal government 等政治证据，也包含 insurers、marketplaces 等商业词。BERT-64 以约 99.3% 概率判 business，全文 Count 与 BERT-512 正确。该例与 4400 不同：主类别线索没有完全缺失，输入短只是限制背景的一部分，类别边界混淆本身仍需解释。

6.6 案例 4043：体育活动中的退伍军人议题

真实 sports，Count 及两种 BERT 长度均判 politics。文章同时有高尔夫康复、女性退伍军人和战争创伤内容，长度扩展没有纠错。前文已核对 Count 的 veterans 与 golf 贡献，证明两方面证据同时存在。这属于栏目标签与多主题内容边界困难的案例，该样本保留原始标签参与评价，体现了多主题文章与单一栏目标签之间的边界问题。

6.7 案例 5964：导语比喻误导主题

真实 business，文章讨论旅行信用卡与机场贵宾室权益，导语用 NCAA 篮球竞猜作比喻。BERT-64 判 sports，全文 Count 与 BERT-512 正确。短输入已包含 credit card perks，但体育

比喻占用较多 token；后续 American Express、年费与金融竞争的展开未被 64 输入充分覆盖。它同时涉及修辞理解和后文缺失，不宜强行归入单一原因。

6.8 案例 7878：第一人称叙述缺少显式主题词

真实 sports，开头是压力、哭泣和团队情感的自述，BERT-64 判 business；全文 Count 也判 business，BERT-512 正确。后文明确提到 soccer、training camp 和国家队成员。Count 错误贡献中含 of、that、is 等高频功能词，说明统计模型可能受到文体和训练相关性的影响。此例支持后文语境有价值，但不证明 512 模型在所有叙事文章上都更强。

6.9 高置信错误与可靠性

BERT-64 的 33 条错误中，24 条最大 softmax 概率不低于 0.9。高置信并不等于正确；类别判定不确定性还包含主题边界、训练偏差与输入截断，softmax 并未充分表达这些因素。本报告没有做独立校准集上的温度缩放或绘制完整可靠性曲线，因此只报告该可核查现象，不声称量化了全局校准误差。

7 结论、局限与复现

7.1 回答研究问题

第一，显式词统计在本数据上很强。主题词对标签有直接判别力，全文 Count 在主要模型中验证 Macro-F1 最高；Binary 与 Count 的测试差距很小，不能根据 1 条错误差认定一种普遍更优。

第二，平均词向量实现了低维表示，但紧凑不保证更准确。三种词向量来源中，NYT 组测试点估计最高，GloVe 验证表现最高。覆盖率、同域共现与语料规模有解释价值，却没有单独决定最终性能。平均操作和单一线性边界对跨主题文档存在限制。

第三，BERT 的优势取决于实验约束。输入长度为 64 时，它低于全文词袋，却优于本次同输入范围的短词袋。BERT-512 结果提示更多上下文有帮助，但改变了多个因素，只能作为探索性补充。模型规模、预训练、输入预算和标签定义必须一起讨论。

7.2 局限与可检验的改进方向

本实验仅一个固定划分与训练种子，bootstrap 不能代替多随机种子重训。主要少数类测试样本各约 140 条，少数几个边界样本即可改变 F1 排名。当前报告的事后错例与消融不构成未被查看过的独立测试。

去重只覆盖完全一致文本；相同事件、来源文风和栏目模板可能同时进入训练与测试。案例 9704 尾部含 Business Day 等栏目提示，全文模型可能利用这种数据捷径。尚未做去模板或按时间/事件划分实验，因此高分不能直接解释为纯粹语义理解或真实部署性能。

GloVe 与 BERT 来自大规模公开预训练，其训练语料是否含这些新闻无法完全排除；三种 T2 来源的规模、词表和目标也不完全相同。因此，观察到的差异反映了表示学习、训练语料和分类器的共同作用。

如果继续研究，应预先固定新实验计划：比较头部、尾部或分段聚合等输入方式；在独立验证集探索停用词处理、加权平均和类别权重；用多个种子报告均值与标准差；对栏目模板移除前后进行对照。这些方向有助于进一步检验模型对语境与数据分布变化的适应能力。

7.3 文件与复现入口

仓库：[MaChuanZhi666/nlp-hw1-text-classification](https://github.com/MaChuanZhi666/nlp-hw1-text-classification)。仓库提供可直接阅读的 PDF 与实验结果。完整复现说明见提交包 README。原始 nyt.csv 与 ag.csv、固定划分清单、指标 JSON 和逐样本预测应一起保存。预训练权重体积大，使用下载脚本和来源哈希重建，不把本地环境目录与模型权重混入代码仓库。

表 19: 文件与复现入口

步骤	脚本/文件	输出
T1 与划分	t1_experiment.py	t1_results
NYT 词向量	t2_experiment.py	t2_results/skipgram.kv
GloVe 准备	prepare_glove.py	models/glove
词向量分类	t2_required.py	t2_required_results
BERT 准备	prepare_bert.py	models/bert-base-uncased
BERT-64	t3_required.py	t3_64_results
补充实验	t1_tfidf.py、bow_head64.py	对应 results 目录
重算与绘图	analyze_required.py	required_analysis
T2 三方证据	analyze_t2_cases.py	required_analysis/t2_case_evidence.json
LaTeX 报告	build_required_report.py	latex_report_revised/main.tex

```
python t1_experiment.py
python t2_experiment.py
python prepare_glove.py
python t2_required.py --models ag nyt glove
python prepare_bert.py
python t3_required.py --batch-size 16 --gradient-accumulation 2 --eval-batch-size 32
python t1_tfidf.py
python bow_head64.py
python analyze_required.py
python analyze_t2_cases.py
python build_required_report.py
```

分析脚本另读取已保存的 BERT-512 结果以生成补充对照；若从零复现所有补充项，按 README 运行 `t3_experiment.py`。BERT-64 对应 `t3_required.py`。LaTeX 源码独立可编辑，用 XeLaTeX 连续编译两次；不需要 Python 才能编辑正文。

7.4 来源及方法参考

1. [GloVe 官方项目页](#)：6B 预训练向量、语料来源与下载。
2. [Pennington 等：GloVe 论文](#)：全局共现词向量方法。
3. [Mikolov 等：Efficient Estimation of Word Representations](#)：Word2Vec 方法。
4. [Gensim Word2Vec 文档](#)：参数与实现。
5. [Devlin 等：BERT 论文](#)：预训练与微调方法。
6. [google-bert/bert-base-uncased 模型页](#)：实际预训练模型来源。
7. [scikit-learn 文本特征提取文档](#)：词袋和 TF-IDF 实现。