

# 自然语言处理作业 1

## NYT 新闻分类：文本表示、性能与误差分析

姓名：马传志      学号：2411788

### 摘要

本实验依据正式作业要求，在同一 NYT 数据划分上比较二值词袋、计数词袋、GloVe、AG News 与 NYT 训练的 Word2Vec，以及输入长度为 64、微调 3 轮的 BERT。所有传统表示均使用逻辑回归，模型参数只按验证集选择。实验不仅报告 Accuracy 与 Macro-F1，也从类别混淆、语料覆盖、正则化、逐样本错误与输入预算对照解释性能差异。全文计数词袋的测试 Macro-F1 为 96.79%，规定的 BERT-64 为 93.95%；而仅使用相同开头内容的计数词袋为 91.47%。这一结果提示：表示能力与可见文本范围共同影响分类效果，不能仅凭模型规模判定优劣。补充实验与规定实验明确区分，历史 512 长度结果不替代规定结果。

**关键词：**新闻分类；词袋模型；逻辑回归；Word2Vec；BERT；误差分析

## 目录

|                                 |          |
|---------------------------------|----------|
| <b>1 任务、数据与实验设计</b>             | <b>3</b> |
| 1.1 研究问题与要求边界                   | 3        |
| 1.2 数据清理与固定划分                   | 3        |
| 1.3 评价、调参及信息隔离                  | 4        |
| 1.4 分类器与统一预处理                   | 4        |
| <b>2 Task 1: 词袋表示及可解释性</b>      | <b>5</b> |
| 2.1 Binary、计数与补充 TF-IDF         | 5        |
| 2.2 结果与参数选择                     | 5        |
| 2.3 训练权重与单篇贡献                   | 6        |
| <b>3 Task 2: 三种来源的 100 维词向量</b> | <b>6</b> |
| 3.1 三组实验的实现与来源                  | 6        |
| 3.2 文档池化、未知词与分类器                | 7        |
| 3.3 正式结果与覆盖率                    | 7        |
| 3.4 可核查的近邻与覆盖反例                 | 8        |

|     |                                |           |
|-----|--------------------------------|-----------|
| 3.5 | 正则化敏感性：验证集证据                   | 8         |
| 3.6 | 补充消融：平均向量再做 L2 归一化             | 9         |
| 3.7 | 三方错例：覆盖率之外的分类证据                | 9         |
| 4   | <b>Task 3：严格按 64 长度微调 BERT</b> | <b>11</b> |
| 4.1 | 模型、tokenization 与训练设置          | 11        |
| 4.2 | 训练曲线与结果                        | 11        |
| 4.3 | 截断审计与同输入范围对照                   | 12        |
| 5   | <b>综合比较与统计不确定性</b>             | <b>14</b> |
| 5.1 | 六组规定实验的总结果                     | 14        |
| 5.2 | 逐类表现：多数类会掩盖什么                  | 15        |
| 5.3 | 文档长度分层                         | 16        |
| 5.4 | 配对比较与结论强度                      | 16        |
| 6   | <b>错误案例：从可见证据到解释</b>           | <b>17</b> |
| 6.1 | 案例选择和证据边界                      | 17        |
| 6.2 | 案例 4400：核心事件出现在导语之后            | 18        |
| 6.3 | 案例 7009：共享语义与不同信息范围            | 18        |
| 6.4 | 案例 9704：不能把错误都归因于截断            | 18        |
| 6.5 | 案例 2849：分类边界而非纯输入缺失            | 18        |
| 6.6 | 案例 4043：体育活动中的退伍军人议题           | 18        |
| 6.7 | 案例 5964：导语比喻误导主题               | 18        |
| 6.8 | 案例 7878：第一人称叙述缺少显式主题词          | 19        |
| 6.9 | 高置信错误与可靠性                      | 19        |
| 7   | <b>结论、局限与复现</b>                | <b>19</b> |
| 7.1 | 回答研究问题                         | 19        |
| 7.2 | 局限与可检验的改进方向                    | 19        |
| 7.3 | 文件与复现入口                        | 20        |
| 7.4 | 来源及方法参考                        | 21        |

## 1 任务、数据与实验设计

### 1.1 研究问题与要求边界

本实验研究：新闻主题分类中，显式词项统计、平均词向量和预训练上下文表示分别带来什么收益与限制？比较重点不仅是总体准确率，也包括少数类别表现、数据来源、输入范围及错误原因。依据课程《作业一要求》，T1 为 30 分、T2 为 50 分、T3 为 20 分；因此将 GloVe、AG News 词向量与 NYT 词向量三组均作为正式实验，而不把 CBOW 与 Skip-gram 两种架构误当作 T2 要求的三组来源。

文档中 T1 总述为“三种”，明细只列 Binary BoW 与 Word Frequency 两种。本报告完成两种明确要求，并将 TF-IDF 列为补充实验；这一处理不意味着老师已指定第三种就是 TF-IDF。正式 BERT 实验严格采用 64 的最大输入长度和 3 个 epoch，历史 512 长度实验仅作为补充观察。

### 1.2 数据清理与固定划分

NYT 原始数据共 11519 条，字段为 text 和 label。检查未发现空文本、缺失标签或相同文本对应冲突标签；有 72 条完全重复记录。为防止同一篇文章跨训练集与测试集造成记忆式收益，先按完整 text 去重，保留 11447 条。原始文件不修改。该预处理属于本实验的明确选择，正式文档并未要求去重，因此报告保留原始数与去重数供复核。

随后采用 seed=42 的分层随机抽样：先分出 20%，再将这部分平分为验证集与测试集，得到近似 80%/10%/10%。两次抽样均 shuffle，符合先随机打乱的原则；分层额外保证类别比例接近。三个集合之间的完全相同文本交集为零。所有方法沿用同一 row\_id 划分清单，不因模型表现重新划分。

表 1: 数据清理与固定划分

| 集合    | business | politics | sports | 合计   |
|-------|----------|----------|--------|------|
| train | 1134     | 1146     | 6877   | 9157 |
| valid | 141      | 144      | 860    | 1145 |
| test  | 142      | 143      | 860    | 1145 |

row\_id 为原始 CSV 从 0 开始的数据行号，不包括表头。测试集 sports 占 75.11%，而 business 与 politics 各约 12.4%。始终预测 sports 即可取得 75.11% 的 Accuracy，但 Macro-F1 仅 28.60%，说明必须同时报告两种指标。

AG News 提供 90000 条文本，去除 29 条完全重复记录后为 89971 条，与完整 NYT 的精确文本交集为零。AG 只用于训练词向量，不使用标签。精确去重不能排除改写、近重复或同一事件报道；本实验未实施事件分组或时间外推划分，因此结论适用于当前随机划分。

### 1.3 评价、调参及信息隔离

$$\text{Accuracy} = \frac{1}{N} \sum_{i=1}^N \mathbf{1}[y_i = \hat{y}_i], \quad (1)$$

$$P_k = \frac{TP_k}{TP_k + FP_k}, \quad R_k = \frac{TP_k}{TP_k + FN_k}, \quad (2)$$

$$F_{1,k} = \frac{2P_k R_k}{P_k + R_k}, \quad \text{Macro-F1} = \frac{1}{3} \sum_{k=1}^3 F_{1,k}. \quad (3)$$

分母为零时按 0 处理。Macro-F1 先逐类计算再平均，不等于将平均 Precision 与平均 Recall 代入调和平均。表中指标均为百分数；“提高 1 个百分点”指两百分数直接相减。

词袋词表、TF-IDF 的 IDF、自训练 NYT 词向量都只拟合 NYT 训练集；AG 词向量只拟合 AG；公开 GloVe 作为固定外部资源。验证集仅用于选择 C 或 BERT checkpoint，测试集不参与梯度更新、词表学习或超参数选择。所有方法均不在选择后合并训练集与验证集重训，以保持数据使用规则一致。

选参统一优先验证集 Macro-F1，LR 平时取较小 C，BERT 平时保留更早 epoch。T1 规定模型 C 取 0.01、0.1、1；T2 和补充 TF-IDF 取 0.01 至 1000 的六个十倍网格点。不同特征尺度对应的合理 C 不同，数值相同不代表正则化强度可直接比较。模型表现已被用于事后解释，新增消融也沿用原测试集，因此它们属于探索性分析，并非新测试集上的独立确认。

### 1.4 分类器与统一预处理

非 BERT 模型均使用小写化与正则分词，保留至少两个字母、数字或下划线组成的 token；不删停用词，不做词干化。该规则对所有词袋和词向量方法一致。作业中的 `nltk.word_tokenize` 是可选建议，并非强制 API；此处明确采用 `CountVectorizer` 分析器以统一实现。

LR 采用 One-vs-Rest、liblinear、L2 正则、带截距、无类别权重、seed=42。每类分别拟合一个二元分类器，预测时取最大决策得分；不是将其误称为多项 softmax 回归。类别概率为 OvR 概率的归一化值，不能直接当作校准后的可靠度。达到最大迭代数的收敛警告会被转为错误；正式运行没有未处理的收敛警告。

$$s_k(d) = \mathbf{w}_k^\top \mathbf{x}_d + b_k, \quad \hat{y} = \arg \max_k s_k(d).$$

较大 C 代表较弱正则化。词袋 max\_iter=2000，新增 T2 与 TF-IDF 为 5000，增大上限只用于保证求解收敛。对不均衡类别不加权是保持基线一致的选择，不代表类别加权无价值。

## 2 Task 1: 词袋表示及可解释性

### 2.1 Binary、计数与补充 TF-IDF

训练集词表大小为 60947。Binary 只记录某词是否出现，Count 保留原始出现次数，不除以文档长度。例如词表为 [team, win, market]，文档 “team team win” 分别得到 [1,1,0] 与 [2,1,0]。未在训练词表出现的测试词被忽略。

$$x_{d,j}^{\text{Binary}} = \mathbf{1}[c_{d,j} > 0], \quad x_{d,j}^{\text{Count}} = c_{d,j}.$$

Binary 降低重复措辞的影响，但抹去了主题词密集程度；Count 保留强度信息，也可能放大背景主题和长文章中重复词的作用。二者均不建模词序，无法直接区分“体育用于营销”与“营销涉及体育”的主次关系。

补充 TF-IDF 使用原始词频乘平滑 IDF，再做逐文档 L2 归一化：

$$\text{idf}(j) = \log \frac{1 + N_{\text{train}}}{1 + \text{df}(j)} + 1, \quad z_{d,j} = c_{d,j} \text{idf}(j), \quad \mathbf{x}_d = \mathbf{z}_d / \|\mathbf{z}_d\|_2.$$

IDF 只用训练集。TF-IDF 同时改变词项权重和向量尺度，因此若表现变化，不能单独归因于“抑制停用词”。

### 2.2 结果与参数选择

表 2: 结果与参数选择

| 方法     | C   | 验证 Acc | 验证 F1 | 测试 Acc | 测试 F1 | 错数 |
|--------|-----|--------|-------|--------|-------|----|
| Binary | 1.0 | 98.52  | 96.31 | 98.60  | 96.85 | 16 |
| Count  | 0.1 | 99.39  | 98.46 | 98.69  | 96.79 | 15 |
| TF-IDF | 100 | 99.30  | 98.23 | 99.04  | 97.53 | 11 |

Count 的验证 Macro-F1 最高，因此按预定规则选 Count 作为 T1 主模型。测试集上 Binary 的 Macro-F1 反而比 Count 高约 0.06 个百分点，而 Count 少错 1 条；这并不矛盾，Macro-F1 对各类等权，不只统计总错数。不能看到测试分数后反过来宣称 Binary 才是验证集选出的模型。

从 Binary 切换到 Count 修正 8 条错误，同时新增 7 条，说明不是单纯在原模型上“多猜对 1 篇”。Count 把 business 正确数从 132 提升至 133，却将 politics 正确数从 140 降至 139，sports 从 857 升至 858；少数类之间的 Precision/Recall 变化使总体 Accuracy 与 Macro-F1 排序不同。

TF-IDF 取得 11 条错误、测试 Macro-F1 为 97.53%，相对 Count 修正 6 条并新增 2 条。它是本次测试上的最好点估计，但验证 Macro-F1 仍低于 Count。后文配对区间跨零，因此不能把一次测试排名写成稳定优势，更不能用该补充结果替代两种规定实验。

## 2.3 训练权重与单篇贡献

表 3: 训练权重与单篇贡献

| 类别       | Count 正权重靠前的词                                                 |
|----------|---------------------------------------------------------------|
| business | company, european, flight, market, wasserman, business, its   |
| politics | military, mr, washington, republican, law, obama, republicans |
| sports   | players, league, team, game, football, season, club           |

这些词揭示语料关联：体育类含 players、league、team，商业类含 company、market，政治类含 military、washington、republican。词权重反映条件于当前训练集的预测关联，不是普遍词义，也不是因果作用。例如“mr”等称谓和功能词也进入模型，提示作者文风与栏目习惯可能成为捷径。

对错误类  $a$  与真实类  $b$ ，使用决策差值而不是仅列某类最大权重：

$$s_a(d) - s_b(d) = (b_a - b_b) + \sum_j x_{d,j}(w_{a,j} - w_{b,j}).$$

每个词的贡献等于实际输入值乘类别权重差。正值推向错误类，负值支持真实类，截距也必须计入总差；只看单词系数而不乘出现次数会误判 Count 模型的证据。

row\_id=4043 实际为 sports，讲女性退伍军人的高尔夫康复活动，Count 误判 politics。veterans 出现 19 次，向错误类贡献 +3.931；golf 出现 13 次，支持真实类贡献-3.505；club 的贡献为-2.356。模型同时识别两类信号，但整篇累积后的线性边界落在 politics 一侧。该例说明跨主题文章的叙事中心不能由是否出现体育词唯一确定。

row\_id=4113 真实 business，讨论保险监管与既有保单。insurance 出现 14 次却对 politics 相对 business 贡献 +3.691，state 贡献 +2.198；companies、consumers 分别贡献-1.161、-0.987。不能按日常常识把 insurance 自动视作商业词：本数据中保险与医疗政策报道高度相关，模型学到的是训练语境中的共现。完整词项贡献保存在 T1 结果 JSON 中，可回查而不是依赖主观猜测。

## 3 Task 2: 三种来源的 100 维词向量

### 3.1 三组实验的实现与来源

GloVe 使用作业指定的 glove.6B.100d.txt，共 400000 词、每词 100 维，来自斯坦福官方 glove.6B.zip，而不是较新的 2024 版或其他维度。官方说明该 6B 模型由 Wikipedia 2014 与 Gigaword 5 语料训练。下载时只读取 ZIP 中的 100d 成员，并由 ZIP CRC 校验完整性；完整文件 SHA-256 保存在来源记录中。

GloVe 利用全局词词共现统计学习表示；Word2Vec 在局部上下文预测任务中学习向量。本实验两种自训练来源统一采用 Skip-gram 与负采样，固定 100 维、window=5、min\_count=2、negative=5、sample=0.001、epochs=10、workers=1、seed=42，使用稳定 CRC32 词哈希。先按句末标点切分句子，再用统一分析器分词，以免窗口跨越无关句子。

AG 组只在 89971 条 AG 文本训练；NYT 组只用 9157 条 NYT 训练文本，复用已完成并校验过的同参数 Skip-gram 向量，不用验证集或测试集训练词向量。CBOW 历史结果不属于作业规定的第四组，也不进入主结果排名。

### 3.2 文档池化、未知词与分类器

对文档中有向量的所有词取平均，重复出现的词重复参与求和；不存在向量的词跳过。这里分母为有效 token 数量，而不是原文词数或不同词的数量。全篇无已知词时使用 100 维零向量，并统计该情况；此次三组在所有划分中均没有零向量文档。

$$\mathcal{I}_d = \{i : w_i \in V_{\text{emb}}\}, \quad h(d) = \frac{1}{|\mathcal{I}_d|} \sum_{i \in \mathcal{I}_d} e(w_i).$$

正式结果直接用该平均向量训练 LR，不额外归一化；L2 归一化只作为独立补充消融。无监督词向量在分类阶段保持固定，不接受 NYT 标签的反向传播。100 维平均向量比 60947 维稀疏词袋紧凑，但将每篇文档压缩为一个中心点，会丢失词序、不同主题段落的位置和部分稀有判别词信息。

### 3.3 正式结果与覆盖率

表 4: 正式结果与覆盖率

| 来源      | 词表大小   | 测试覆盖率 | C   | 验证 F1 | 测试 Acc | 测试 F1 |
|---------|--------|-------|-----|-------|--------|-------|
| GloVe   | 400000 | 99.76 | 100 | 97.53 | 98.08  | 95.58 |
| AG-W2V  | 37021  | 97.05 | 100 | 95.98 | 97.90  | 94.99 |
| NYT-W2V | 43337  | 99.18 | 100 | 97.15 | 98.34  | 96.04 |

覆盖率按已知 token 总数除以总 token 数计算，计入重复词，不是词类型覆盖率。GloVe 覆盖率最高，但测试 Macro-F1 并未最高；NYT 词向量测试 Macro-F1 高于 AG 约 1.05 个百分点，高于 GloVe 约 0.46 个百分点。差异很小且配对区间均跨零，应将“同域语料可能有帮助”作为解释线索，而不是已被确定证明的普遍规律。

AG 有近 9 万篇，数量多于 NYT 训练集约 9 千篇，但不能仅按文档数量判断训练资源。AG 训练句子的 token 总量约 338 万；NYT 训练文本经统一文档分析器得到约 572 万 token，且 NYT 文章更长。来源、长度、词频分布与共现样本总量共同变化，所以当前实验不是只改变“域”的严格单因素实验。

GloVe 的高覆盖率主要避免未知词丢失，却不能保证平均向量能保持分类所需的主次关系。外部向量中的语义近邻也未必对应本作业的栏目标签。比如 government 与 economy 相关是合理语言现象，却可能使 business/politics 两类更难通过平均向量分开。

### 3.4 可核查的近邻与覆盖反例

表 5: 可核查的近邻与覆盖反例

| 来源      | market 最近邻                    | government 最近邻                         |
|---------|-------------------------------|----------------------------------------|
| GloVe   | markets, stock, prices        | administration, governments, officials |
| AG-W2V  | cooled, markets, fundamentals | upa, ministries, iyad                  |
| NYT-W2V | markets, economy, stocks      | shutdown, federal, economy             |

GloVe 中 market 邻近 markets、stock、prices, NYT 中 government 邻近 shutdown、federal、economy, 体现当前 NYT 政治经济报道的语境。AG 的一些近邻是专名或较生僻词, 说明有限语料与词频估计会影响近邻质量; 这里只作局部观察, 不能根据三个词的近邻直接评定整体向量优劣。

进一步按每篇文档覆盖率 98% 分组: AG 低覆盖组 812 篇、错 15 篇, 准确率 98.15%; 高覆盖组 333 篇、错 9 篇, 准确率 97.30%。GloVe 低覆盖组只有 11 篇且恰好全对, 样本太少不宜推断。这个反例表明覆盖率与错误并非简单单调关系, 文章主题、长度和难度都是混杂因素; 不能写成“所有错误都由 OOV 导致”。

### 3.5 正则化敏感性: 验证集证据

表 6: 正则化敏感性: 验证集证据

| C    | GloVe 验证 F1 | AG 验证 F1 | NYT 验证 F1 |
|------|-------------|----------|-----------|
| 0.01 | 81.54       | 40.73    | 52.45     |
| 0.1  | 93.08       | 89.38    | 90.19     |
| 1    | 96.39       | 93.84    | 93.91     |
| 10   | 97.40       | 95.14    | 96.97     |
| 100  | 97.53       | 95.98    | 97.15     |
| 1000 | 97.53       | 95.85    | 96.92     |

三组均选择 C=100, GloVe 在 100 与 1000 上平分而取较小值。小 C 时较强的收缩会令 100 维密集表示难以划出合适边界, 特别是少数类; 放松正则后验证 F1 明显上升。继续增大到 1000, AG 与 NYT 没有改善, 提示不能简单认为 C 越大越好。模型选择使用验证表现, 而不是挑测试最高的 C。

### 3.6 补充消融：平均向量再做 L2 归一化

表 7: 补充消融：平均向量再做 L2 归一化

| 来源      | 原平均 C | 原平均测试 F1 | L2 后 C | L2 后测试 F1 |
|---------|-------|----------|--------|-----------|
| GloVe   | 100   | 95.58    | 100    | 95.78     |
| AG-W2V  | 100   | 94.99    | 1000   | 95.12     |
| NYT-W2V | 100   | 96.04    | 1000   | 96.04     |

两种处理各自用相同六点网格在验证集选 C，测试差异均很小。NYT 归一化后总错数仍为 19，但类别分配稍变，所以 F1 并不完全相同。AG 和 NYT 归一化版本选到网格上界 1000，其最佳 C 尚未被上方候选包围，不能宣称已全局调优。归一化改变向量长度和有效正则尺度，所以差异不能仅解释为删除文档长度信息；平均向量范数还受语义一致性和词向量范数影响。

### 3.7 三方错例：覆盖率之外的分类证据

从三组预测不一致的文章中，事后选取 AG 单独误判、NYT 单独误判、GloVe 单独误判各一例，避免只展示某一来源获胜的样本。这些案例用于解释，不能据此估计三组的总体胜率。完整原文、未知词、概率和逐词贡献保存在 `required_analysis/t2_case_evidence.json`。

表 8: 三方错例：覆盖率之外的分类证据

| row_id/真实类     | 来源    | 预测       | 覆盖率 (%) | 类别分差   |
|----------------|-------|----------|---------|--------|
| 2849/politics  | glove | politics | 99.83   | -3.060 |
| 2849/politics  | ag    | business | 99.17   | +1.770 |
| 2849/politics  | nyt   | politics | 99.50   | -0.004 |
| 9704/business  | glove | business | 99.89   | -1.295 |
| 9704/business  | ag    | business | 96.47   | -0.604 |
| 9704/business  | nyt   | sports   | 97.83   | +3.530 |
| 11327/business | glove | sports   | 100.00  | +0.588 |
| 11327/business | ag    | business | 98.12   | -2.488 |
| 11327/business | nyt   | business | 98.74   | -2.175 |

2849 的分差为 business 减 politics，另外两篇为 sports 减 business；正值支持此处的错误类别。各模型分别训练，分差尺度不能跨模型解释为统一置信度。对固定平均词向量加线性分类器，可精确分解：

$$s_a(d) - s_b(d) = (b_a - b_b) + \sum_{w \in V_d} \frac{c_d(w)}{n_d} (\mathbf{w}_a - \mathbf{w}_b)^\top \mathbf{e}(w).$$

其中  $n_d$  为已知 token 总数,  $V_d$  为文档中已知词的集合, 重复词由次数  $c_d(w)$  计入。分析脚本检查“全部词贡献之和加截距”与实际类别分差一致 (误差小于 0.0001)。这能定位线性决策的数值来源, 但不是删除该词后的因果效果: 删除词还会改变平均分母。

### 3.7.1 案例 2849: 保险产品等级与公共政策混淆

文章介绍医保交易平台、联邦政府公布的保险计划与价格, 真实为 politics。AG 判 business, GloVe 和 NYT 正确。三者覆盖率都超过 99%, AG 仅缺失 varieties、comanche、923、optima、064 五个各出现一次的 token。因此不能简单归因为大量政治词缺失。

在 AG 模型中, gold 出现 6 次, 对 business 减 politics 的分差贡献 +1.466; premium 贡献 +0.575, 而 federal 贡献 -0.062、government 贡献 -0.197。原文 gold 和 silver 指保险计划等级; 固定词向量不会随当前语境改变, 平均表示也不保留修饰关系。结合全部词与截距, AG 最终分差为 +1.770, 落入 business。这里不能断言 gold 被内部解释成贵金属, 只能确认其数值贡献推向商业类。NYT 的分差约 -0.004, 虽然正确, 却非常接近边界, 并非同域词向量在此例具有压倒性优势。

### 3.7.2 案例 9704: 体育题材服务于酒店营销

文章讲万豪借棒球电影推广会员计划, 真实为 business。GloVe 与 AG 正确, NYT 误判 sports。AG 覆盖率 96.47%, 低于 NYT 的 97.83%, 却分类正确, 直接反驳“覆盖率更高就一定分类更好”。AG 未知词包括 facebook、screenings 和 multicultural; 但核心品牌 marriott 在三组词表中都存在。

marriott 出现 24 次, 在 GloVe 和 AG 中对 sports 减 business 分别贡献 -2.135 和 -2.088, 在 NYT 中仅为 -0.177。NYT 的 robinson、baseball、league 分别贡献 +0.805、+0.708、+0.700; 所有词与截距合计后分差为 +3.530。问题不只是未知词, 还涉及已知词向量与分类器共同形成的判别方向。由于三组 LR 也分别训练, 不能把贡献差异全部归因于词向量本身, 更不能由这篇反例推出同域训练普遍无效。

### 3.7.3 案例 11327: 冰球商品的关税报道

文章讨论加拿大取消体育用品进口关税及零售价格, 真实为 business。GloVe 误判 sports, AG 与 NYT 正确。GloVe 覆盖率 100%, 没有未知词, 说明该错误完全不能用 OOV 解释。hockey 出现 13 次, 对 GloVe 的 sports 减 business 贡献 +3.524; tariffs 和 prices 分别贡献 -0.155 和 -0.401, 最终分差仍为 +0.588。

AG 与 NYT 中的 hockey 同样推向 sports, 贡献分别为 +3.333 和 +3.002, 但全篇其他词与截距共同使分差降为 -2.488 和 -2.175, 得到 business。不能只取最大正贡献词就判断模型输出; 平均表示加 LR 依赖的是整篇净证据。此例和 9704 共同显示, 体育实体既可能是报道主旨, 也可能只是商业活动的对象, 平均池化难以显式区分这两种关系。

三例说明: 覆盖率衡量词是否可用, 逐词贡献解释当前线性分类器怎样累计证据, 二者都不能单独代表篇章理解能力。主结果中 NYT 的测试点估计最高, 但 AG 与 GloVe 各自也有正确而

NYT 错误的样本，因此仍保留三来源差异区间跨零的结论。

## 4 Task 3: 严格按 64 长度微调 BERT

### 4.1 模型、tokenization 与训练设置

使用 google-bert/bert-base-uncased 的预训练权重，固定仓库 revision；添加三分类头，对全部参数微调。模型共有 109484547 个参数。使用标准 BERT 序列分类结构：CLS 位置经过 pooler、dropout 和线性分类头，不把平均词向量送入另一个 LR。

Tokenizer 设置 max\_length=64、truncation=True，保留开头最多 62 个正文 WordPiece，再加 CLS 和 SEP。动态 padding，attention\_mask 区分正文与 padding，单文本 token\_type\_ids 均为 0。完整长度只用于统计截断情况，不送入模型训练，也不用于选参。

严格训练 3 轮，AdamW 学习率  $2e-5$ ，weight\_decay=0.01（bias 和 LayerNorm 权重不衰减），前 10% 更新线性 warmup，其后线性衰减；梯度裁剪 1.0。micro-batch=16、累积 2 步，有效 batch 约 32；最后不足一组时按实际样本数缩放梯度。验证 batch=32，无类别加权。固定 Python、NumPy 与 Torch 种子 42；不同 CUDA 内核与混合精度环境仍可能出现微小差异。

实验在用户授权的 RTX A6000 48GB 服务器进行，PyTorch 2.1.2+cu121、Transformers 4.46.3、Python 3.8.10，使用 BF16。采用验证 Macro-F1 最高的 checkpoint，3 轮训练全部完成后才进行最终测试；本次恰好选中第 3 轮，因此最终结果也对应训练满 3 轮的模型。

### 4.2 训练曲线与结果

表 9: 训练曲线与结果

| Epoch | 训练损失   | 验证损失   | 验证 Acc | 验证 F1 |
|-------|--------|--------|--------|-------|
| 1     | 0.2785 | 0.0789 | 97.38  | 93.76 |
| 2     | 0.0475 | 0.0632 | 97.64  | 94.38 |
| 3     | 0.0183 | 0.0707 | 97.90  | 94.99 |




图 1: BERT-64 训练与验证损失

训练损失持续下降，但验证交叉熵在第 2 轮最低，第 3 轮回升；验证 Macro-F1 却继续上升。损失衡量概率质量，F1 衡量离散分类结果，少量更自信的误差即可拉高损失，因此两者不必同步。这里按预先指定的 Macro-F1 选择第 3 轮，不能在看到测试后改用损失最低的 epoch。

最终测试 Accuracy 为 97.12%，Macro-F1 为 93.95%，错误 33 篇。完整运行约 147.3 秒，峰值已分配显存约 2390MiB；该时间包含本脚本的处理、验证与保存，不包含下载预训练权重。不同模型运行平台与统计阶段不同，不能把这些数字当成严格的跨模型速度排名。

### 4.3 截断审计与同输入范围对照

表 10: 截断审计与同输入范围对照

| 集合    | 平均长度  | 截断篇数/总数   | 保留比例 (%) |
|-------|-------|-----------|----------|
| train | 833.8 | 9152/9157 | 7.44     |
| valid | 825.0 | 1145/1145 | 7.52     |
| test  | 826.8 | 1145/1145 | 7.50     |

表中长度单位为正文 WordPiece。测试集 1145 篇均超过可保留的 62 个正文 WordPiece，保留 token 总量仅约 7.50%。这一数值不是“保留 7.50% 的语义信息”：新闻导语往往浓缩核心内容，字符、词与信息量也不成比例。不能因为截断普遍发生，就证明每个错误都由截断导致。

为减少输入范围的混杂，补充 Count-head64：将同一 BERT tokenizer 产生的前 62 个正文 WordPiece 解码为文本，再用 CountVectorizer 与 LR 训练；训练、验证、测试都执行相同处理。原三点网格的最优  $C=1$  位于上界；本次预先扩展到 0.01、0.1、1、10、100、1000 六点，只按验证 Macro-F1 选  $C$ ，平分取较小值，选定后才计算测试指标。两种模型可见的原文范围相同，但后续分词表示、预训练资源与搜索空间并非完全相同，因此是输入预算对照，不是架构唯一变化的纯因果实验。

表 11: 截断审计与同输入范围对照

| 配置           | 测试 Acc | 测试 F1 | 错误数 |
|--------------|--------|-------|-----|
| Count        | 98.69  | 96.79 | 15  |
| Count-head64 | 95.81  | 91.47 | 48  |
| BERT-64      | 97.12  | 93.95 | 33  |
| BERT-512     | 98.69  | 96.98 | 15  |

表 12: 截断审计与同输入范围对照

| 短 Count 的 C | 验证 Acc | 验证 Macro-F1 |
|-------------|--------|-------------|
| 0.01        | 90.66  | 80.88       |
| 0.1         | 94.67  | 89.12       |
| 1           | 95.46  | 90.41       |
| 10          | 95.63  | 90.74       |
| 100         | 95.46  | 90.35       |
| 1000        | 95.55  | 90.51       |

扩展网格选中  $C=10$ , 其验证 Macro-F1 为 90.74%, 高于  $C=1$  的 90.41%; 继续增大至 100 和 1000 均未超过  $C=10$ , 最优点已被两侧候选包围。测试 Accuracy 从 95.72% 升至 95.81%, Macro-F1 从 91.33% 升至 91.47%, 错误由 49 篇降为 48 篇。改善有限, 但补足了原先网格边界的疑问; 有限网格仍不等于连续参数的全局最优。

BERT-64 较更新后的短 Count 的 Macro-F1 高 2.48 个百分点, 修正 28 条并新增 13 条错误, 配对 bootstrap 的 95% 区间约为  $[+0.24, +4.77]$  个百分点。这支持本次同输入范围下预训练方案的收益, 且结论没有因扩大短 Count 搜索而反转。后续分词、预训练资源及模型结构仍不同, 不能把差值解释为单一架构因素的因果效果。由于此次扩展发生在已查看原测试结果之后, 仍属于探索性补充。

历史 BERT-512 (头 255、尾 254 个正文 WordPiece, 双片段) 测试 Macro-F1 为 96.98%, 高出 3.03 个百分点。但长度、位置与 segment 编码同时改变, 这不是只改变长度的严格消融, 也不能替代规定的 64 长度结果。

## 5 综合比较与统计不确定性

### 5.1 六组规定实验的总结果

表 13: 六组规定实验的总结果

| 方法      | 验证 Acc | 验证 F1 | 测试 Acc | 测试 F1 | 错误数 |
|---------|--------|-------|--------|-------|-----|
| Binary  | 98.52  | 96.31 | 98.60  | 96.85 | 16  |
| Count   | 99.39  | 98.46 | 98.69  | 96.79 | 15  |
| GloVe   | 99.04  | 97.53 | 98.08  | 95.58 | 22  |
| AG-W2V  | 98.43  | 95.98 | 97.90  | 94.99 | 24  |
| NYT-W2V | 98.86  | 97.15 | 98.34  | 96.04 | 19  |
| BERT-64 | 97.90  | 94.99 | 97.12  | 93.95 | 33  |




图 2: 规定实验总体指标，横轴从 0 开始

在规定的实验中，Count 的验证 Macro-F1 最高，应按验证规则选为整体主模型；Binary 测试 Macro-F1 略高不改变这一选择。T2 内部验证分数最高的是 GloVe，而测试最高的是 NYT-W2V，这个排序反转再次说明不能用测试集选模型。补充 TF-IDF 测试点估计最好，但不在规定六组的主图中混排。

## 5.2 逐类表现：多数类会掩盖什么

表 14: 逐类表现：多数类会掩盖什么

| 方法      | Business F1 | Politics F1 | Sports F1 |
|---------|-------------|-------------|-----------|
| Binary  | 95.65       | 95.24       | 99.65     |
| Count   | 95.00       | 95.53       | 99.83     |
| GloVe   | 93.91       | 93.24       | 99.59     |
| AG-W2V  | 92.63       | 92.68       | 99.65     |
| NYT-W2V | 94.20       | 94.20       | 99.71     |
| BERT-64 | 91.55       | 91.29       | 99.01     |

表 15: 逐类表现：多数类会掩盖什么

| 模型/类别            | Precision | Recall | F1    | Support |
|------------------|-----------|--------|-------|---------|
| Count/business   | 96.38     | 93.66  | 95.00 | 142     |
| Count/politics   | 93.92     | 97.20  | 95.53 | 143     |
| Count/sports     | 99.88     | 99.77  | 99.83 | 860     |
| BERT-64/business | 91.55     | 91.55  | 91.55 | 142     |
| BERT-64/politics | 90.97     | 91.61  | 91.29 | 143     |
| BERT-64/sports   | 99.07     | 98.95  | 99.01 | 860     |




图 3: 六组模型混淆矩阵，行是真实类别，列是预测类别

体育类样本多且词汇信号清晰，各方法总体表现较高；商业与政治共享监管、保险、税收、能源和政府等主题，是主要混淆边界。例如 AG 词向量把 9 篇 business 判成 politics，又把 9 篇 politics 判成 business；GloVe 对应 10 与 5 篇；NYT 对应 10 与 4 篇。平均向量可能把共享语义拉近，但这只是符合混淆模式的解释，不能当作已观测到的内部因果机制。

BERT-64 在 business 与 politics 之间双向各错 8 篇，还各有 4 篇被判 sports。它也把 9 篇 sports 错分到另外两类。与 Count 相比，sports 正确数从 858 降至 851，politics 从 139 降至 131，business 从 133 降至 130，因此下降不限于单一少数类。

### 5.3 文档长度分层

表 16: 文档长度分层

| 普通 token 长度 | 样本数 | B/P/S      | Count 错误 | BERT-64 错误 | 短 Count 错误 |
|-------------|-----|------------|----------|------------|------------|
| 0-199       | 86  | 1/4/81     | 0        | 0          | 0          |
| 200-499     | 270 | 32/22/216  | 1        | 7          | 7          |
| 500-999     | 730 | 99/106/525 | 11       | 22         | 31         |
| 1000 及以上    | 59  | 10/11/38   | 3        | 4          | 10         |

长度按统一词袋分析器的 token 计数，不能与 BERT WordPiece 数混用。最短组 86 篇中 81 篇为 sports，三模型均全对，不代表短文本普遍容易。最长组仅 59 篇，短 Count 有 10 条错误、BERT-64 有 4 条、全文 Count 有 3 条。不同长度组的类别比例与主题难度不同，所以不能由该表断言“长度增加必然降低准确率”，也不能仅凭相关性量化截断的因果影响。

### 5.4 配对比较与结论强度

在同一测试集上对样本索引成对 bootstrap，固定 seed=42，重复 3000 次，每次对两个模型使用相同索引；计算后者减前者的 Macro-F1 差值，取 2.5% 与 97.5% 分位数。该区间只反映固定训练模型与当前测试分布下的样本波动，不含重训随机性。另用不一致预测对做精确二项 McNemar 检验，其检验对象是错误率差异，并非直接检验 Macro-F1。

表 17: 配对比较与结论强度

| 前者 → 后者                   | 修正/新增 | F1 差 (百分点) | 95% 区间         | McNemar p |
|---------------------------|-------|------------|----------------|-----------|
| Binary → Count            | 8/7   | -0.06      | [-1.57, +1.46] | 1.0000    |
| Count → TF-IDF            | 6/2   | +0.74      | [-0.43, +1.97] | 0.2891    |
| AG-W2V →<br>NYT-W2V       | 10/5  | +1.05      | [-0.39, +2.60] | 0.3018    |
| GloVe → NYT-W2V           | 9/6   | +0.46      | [-0.83, +1.80] | 0.6072    |
| Count → BERT-64           | 8/26  | -2.84      | [-5.06, -0.65] | 0.0029    |
| Count-head64 →<br>BERT-64 | 28/13 | +2.48      | [+0.24, +4.77] | 0.0275    |
| BERT-64 → BERT-512        | 24/6  | +3.03      | [+1.14, +5.03] | 0.0014    |

Binary/Count、Count/TF-IDF 以及 T2 来源之间的区间均跨零，不支持把小幅排名差距说成稳定提升。Count 到 BERT-64 的 Macro-F1 差区间为负，短 Count 到 BERT-64 为正，和输入预算分析一致。但这些比较含事后选择且未做多重比较校正，应视为探索性证据；不能推广为所有新闻数据或任意训练种子下的定论。

## 6 错误案例：从可见证据到解释

### 6.1 案例选择和证据边界

以下案例按错误类型人工选取，旨在解释机制，不是随机样本，也不能据此估计某类原因在全部错误中的占比。每个 row\_id 可在原始数据、逐样本预测和 BERT 输入审计中定位。模型原始分数可检查，BERT “关注了哪个词” 没有通过归因实验验证，因此只讨论可见文本与预测的相容解释，不将阅读者的理解冒充模型内部推理。

表 18: 案例选择和证据边界

| row_id | 真实       | Count    | GloVe    | NYT-W2V  | BERT-64  | BERT-512 |
|--------|----------|----------|----------|----------|----------|----------|
| 4400   | sports   | sports   | sports   | sports   | business | sports   |
| 7009   | politics | business | business | business | business | politics |
| 9704   | business | business | business | sports   | sports   | sports   |
| 2849   | politics | politics | politics | politics | business | politics |
| 4043   | sports   | politics | politics | politics | politics | politics |
| 5964   | business | business | business | business | sports   | business |
| 7878   | sports   | business | sports   | sports   | business | sports   |

## 6.2 案例 4400：核心事件出现在导语之后

真实标签 sports。前 62 个正文 WordPiece 主要介绍 Anthony Bosch、商人、投资者与诊所，BERT-64 以约 99.7% 概率判 business；后续才说明诊所牵涉职业棒球兴奋剂丑闻，包括 Major League Baseball 与球员。全文 Count 和历史 BERT-512 均正确。此处确实能在输入审计中看到关键体育信息被 64 截断排除，支持“主旨延后导致信息不足”的解释；但仍不能证明仅把某一个词补回就必然纠错。

## 6.3 案例 7009：共享语义与不同信息范围

真实标签 politics，主题为废弃天然气井的公共治理。开头聚焦价格下降、企业消失与破产，64 输入在费用讨论处截断；州长拨款、议会问责等信息在后文。BERT-64 和全文 Count 都判 business，历史 512 模型正确。Count 虽然读到全文，但 company 与 companies 合计对错误类别贡献约 +7.668，state 则支持 politics 约-5.715，说明它与 BERT-64 错误相同，失误路径却可能不同：一个缺少后文，一个有后文但词项累积边界不合适。

## 6.4 案例 9704：不能把错误都归因于截断

真实标签 business。文章讲万豪借 Jackie Robinson 电影推广会员计划，开头已经明确包含 marriott、promote、loyalty program 和 campaign，BERT-64 仍判 sports，置信度约 99.6%；历史 512 也判 sports，而 Count 正确。体育实体在这里服务于商业营销。因为商业线索已在可见输入里，不能声称“BERT 没看到任何商业信息”；更合理的解释是跨主题主次关系没有被正确区分，但需要额外归因或反事实实验才能验证模型具体依赖什么。

## 6.5 案例 2849：分类边界而非纯输入缺失

真实标签 politics，涉及医保交易平台开放、联邦政府与保险价格。前 62 个 WordPiece 已包含 partisan debate、federal government 等政治证据，也包含 insurers、marketplaces 等商业词。BERT-64 以约 99.3% 概率判 business，全文 Count 与历史 512 正确。该例与 4400 不同：主类别线索没有完全缺失，输入短只是限制背景的一部分，类别边界混淆本身仍需解释。

## 6.6 案例 4043：体育活动中的退伍军人议题

真实 sports，Count 及两种 BERT 长度均判 politics。文章同时有高尔夫康复、女性退伍军人和战争创伤内容，长度扩展没有纠错。前文已核对 Count 的 veterans 与 golf 贡献，证明两方面证据同时存在。这属于栏目标签与多主题内容边界困难的案例，不能未经人工标注复核就把原标签改成 politics，或把错误剔除来提高分数。

## 6.7 案例 5964：导语比喻误导主题

真实 business，文章讨论旅行信用卡与机场贵宾室权益，导语用 NCAA 篮球竞猜作比喻。BERT-64 判 sports，全文 Count 与历史 512 正确。短输入已包含 credit card perks，但体育比喻

占用较多 token；后续 American Express、年费与金融竞争的展开未被 64 输入充分覆盖。它同时涉及修辞理解和后文缺失，不宜强行归入单一原因。

## 6.8 案例 7878：第一人称叙述缺少显式主题词

真实 sports，开头是压力、哭泣和团队情感的自述，BERT-64 判 business；全文 Count 也判 business，历史 512 正确。后文明确提到 soccer、training camp 和国家队成员。Count 错误贡献中含 of、that、is 等高频功能词，说明统计模型可能受到文体和训练相关性的影响。此例支持后文语境有价值，但不证明 512 模型在所有叙事文章上都更强。

## 6.9 高置信错误与可靠性

BERT-64 的 33 条错误中，24 条最大 softmax 概率不低于 0.9。高置信并不等于正确；类别判定不确定性还包含主题边界、训练偏差与输入截断，softmax 并未充分表达这些因素。本报告没有做独立校准集上的温度缩放或绘制完整可靠性曲线，因此只报告该可核查现象，不声称量化了全局校准误差。

# 7 结论、局限与复现

## 7.1 回答研究问题

第一，显式词统计在本数据上很强。主题词对标签有直接判别力，全文 Count 在规定实验中验证 Macro-F1 最高；Binary 与 Count 的测试差距很小，不能根据 1 条错误差认定一种普遍更优。

第二，平均词向量实现了低维表示，但紧凑不保证更准确。三组规定 T2 均已实际完成；NYT 组测试点估计最高，GloVe 验证表现最高。覆盖率、同域共现与语料规模有解释价值，却没有单独决定最终性能。平均操作和单一线性边界对跨主题文档存在限制。

第三，BERT 的优势取决于实验约束。严格 64 长度下，它低于全文词袋，却优于本次同输入范围的短词袋。历史 512 结果提示更多上下文有帮助，但改变了多个因素，只能作为探索性补充。模型规模、预训练、输入预算和标签定义必须一起讨论。

## 7.2 局限与可检验的改进方向

本实验仅一个固定划分与训练种子，bootstrap 不能代替多随机种子重训。主要少数类测试样本各约 140 条，少数几个边界样本即可改变 F1 排名。当前报告的事后错例与消融不构成未被查看过的独立测试。

去重只覆盖完全一致文本；相同事件、来源文风和栏目模板可能同时进入训练与测试。案例 9704 尾部含 Business Day 等栏目提示，全文模型可能利用这种数据捷径。尚未做去模板或按时间/事件划分实验，因此高分不能直接解释为纯粹语义理解或真实部署性能。

GloVe 与 BERT 来自大规模公开预训练，其训练语料是否含这些新闻无法完全排除；三种 T2 来源的规模、词表和目标也不完全相同。报告比较的是作业规定的实际方案，不能将全部差异归因于某一个算法因素。

如果继续研究，应预先固定新实验计划：在不改变正式 64 长度结果的前提下，比较头部、尾部或分段聚合；在独立验证集探索停用词处理、加权平均和类别权重；用多个种子报告均值与标准差；对栏目模板移除前后进行对照。上述项目尚未完成，不作为本报告已有成果。

### 7.3 文件与复现入口

仓库：[MaChuanZhi666/nlp-hw1-text-classification](https://github.com/MaChuanZhi666/nlp-hw1-text-classification)。老师可直接查看 PDF 与已保存结果，无需运行程序。完整复现说明见提交包 README。原始 nyt.csv 与 ag.csv、固定划分清单、指标 JSON 和逐样本预测应一起保存。预训练权重体积大，使用下载脚本和来源哈希重建，不把本地环境目录与模型权重混入代码仓库。

表 19: 文件与复现入口

| 步骤       | 脚本/文件                     | 输出                                      |
|----------|---------------------------|-----------------------------------------|
| T1 与划分   | t1_experiment.py          | t1_results                              |
| NYT 词向量  | t2_experiment.py          | t2_results/skipgram.kv                  |
| GloVe 准备 | prepare_glove.py          | models/glove                            |
| 规定 T2    | t2_required.py            | t2_required_results                     |
| BERT 准备  | prepare_bert.py           | models/bert-base-uncased                |
| 规定 T3    | t3_required.py            | t3_64_results                           |
| 补充实验     | t1_tfidf.py、bow_head64.py | 对应 results 目录                           |
| 重算与绘图    | analyze_required.py       | required_analysis                       |
| T2 三方证据  | analyze_t2_cases.py       | required_analysis/t2_case_evidence.json |
| LaTeX 报告 | build_required_report.py  | latex_report_revised/main.tex           |

```
python t1_experiment.py
python t2_experiment.py
python prepare_glove.py
python t2_required.py --models ag nyt glove
python prepare_bert.py
python t3_required.py --batch-size 16 --gradient-accumulation 2 --eval-batch-size 32
python t1_tfidf.py
python bow_head64.py
python analyze_required.py
python analyze_t2_cases.py
python build_required_report.py
```

分析脚本另读取已保存的历史 BERT-512 结果以生成补充对照；若从零复现所有补充项，按 README 运行 `t3_experiment.py`。正式任务只要求 `t3_required.py`。LaTeX 源码独立可编辑，用 XeLaTeX 连续编译两次；不需要 Python 才能编辑正文。

#### 7.4 来源及方法参考

1. 课程文档《作业一要求》：实验范围、数据比例、维度、指标、BERT 长度与轮数依据。提交物为 PDF、完整代码及运行说明，以包含全部文件的 GitHub 链接提交；原文截止为 10 月 12 日上午 11:55。
2. [GloVe 官方项目页](#)：6B 预训练向量、语料来源与下载。
3. [Pennington 等：GloVe 论文](#)：全局共现词向量方法。
4. [Mikolov 等：Efficient Estimation of Word Representations](#)：Word2Vec 方法。
5. [Gensim Word2Vec 文档](#)：参数与实现。
6. [Devlin 等：BERT 论文](#)：预训练与微调方法。
7. [google-bert/bert-base-uncased 模型页](#)：实际预训练模型来源。
8. [scikit-learn 文本特征提取文档](#)：词袋和 TF-IDF 实现。